


Accélérer le Cycle de Vie du Machine Learning avec MLflow

De l'expérimentation artisanale au LLMOps :
une plateforme unifiée pour l'IA industrielle.






Une présentation technique destinée aux équipes
Data & DevOps pour comprendre comment
standardiser la production de modèles.

PROJECT: INDUSTRIAL AI PLATFORM
VERSION: 1.0.0
DATE: 2024-05-22
STATUS: ACTIVE
TECH STACK: MLFLOW, PYTHON, KUBERNETES, AWS




Le défi unique du développement ML : Gérer le chaos de l'expérimentation

Contrairement au génie logiciel traditionnel qui vise des exigences fonctionnelles, le ML vise l'optimisation de métriques (précision, latence), nécessitant des itérations constantes.

			
Outils fragmentés Les Data Scientists veulent tester Pandas, Spark, TensorFlow, LangChain... mais ces outils ne communiquent pas.	Suivi impossible 'Quel dataset a produit ce modèle ?' Sans suivi rigoureux, les expérimentations sont perdues.	Reproductibilité La difficulté de reproduire un résultat sur une autre machine ("It works on my machine").	Déploiement complexe Le passage de témoin risqué entre le Data Scientist (Python/R) et l'Ingénieur (Java/C++/Docker).

La philosophie MLflow : Une interface ouverte et unifiée



Au lieu de verrouiller les équipes dans une plateforme propriétaire, MLflow propose des APIs ouvertes (REST, Python, R, Java) pour gérer les trois piliers historiques : Tracking, Projects, Models — et désormais l'IA Générative (MLflow 3).


MLflow Tracking : La source de vérité de vos expérimentations

Le Code (Python)

```
import mlflow

# Démarrage automatique ou manuel
with mlflow.start_run():
    mlflow.log_param('num_dimensions', 8)
    mlflow.log_metric('accuracy', 0.8)
    mlflow.log_artifact('roc_curve.png')
```

L'Interface (UI)




The screenshot shows the MLflow Tracking web interface. At the top, there's a navigation bar with the MLflow logo and links to GitHub and Docs. Below that, the breadcrumb 'Experiment > Miflow Tracking' is visible. The main heading is 'Listing Price Prediction'. The 'Experiment ID' is 0, and the 'Artifact Location' is '/Users/matel/mlflow/demo/intruns/0'. There are search filters: 'Search Runs' with the query 'metrics.R2 > 6.24', 'Filter Params' with 'alpha, lr', and 'Filter Metrics' with 'rmse, r2'. A 'Search' button is present. Below the filters, it says '4 matching runs' and provides buttons for 'Compare Selected' and 'Download CSV'. A table of runs is displayed with columns for Time, User, Source, Version, Parameters (alpha, l1_ratio), and Metrics (MAE, R2, RMSE). Four runs are listed, all with a time of 17:37, user 'matel', source 'linear.py', and version '3a1995'. The parameters and metrics vary across the runs.

	Time	User	Source	Version	Parameters	Metrics			
					alpha	l1_ratio	MAE	R2	RMSE
☐	17:37	matel	linear.py	3a1995	0.5	0.2	64.27	0.277	158.1
☐	17:37	matel	linear.py	3a1995	0.2	0.5	64.08	0.264	158.8
☐	17:37	matel	linear.py	3a1995	0.5	0.5	64.12	0.272	158.6
☐	17:37	matel	linear.py	3a1995	0	0	64.49	0.249	161.2

L'interface permet de comparer visuellement des centaines de runs, de filtrer par métriques (ex : **metrics.R2 > 0.24**) et de centraliser les résultats d'une équipe entière.


MLflow Projects : Garantir la reproductibilité technique

Un format standard pour packager le code de data science de manière réutilisable.



- ✓ **Gestion des dépendances :**
Définit automatiquement l'environnement (Conda, Docker) nécessaire à l'exécution.
- ✓ **Exécution universelle :**
Peut être lancé localement ou à distance (Cloud) via une simple commande CLI (``mlflow run git@github...``).
- ✓ **Traçabilité :** MLflow mémorise la version exacte du projet (commit Git) utilisée.


MLflow Models : Le format universel de packaging



Le concept de 'Flavors' (Saveurs) : Un modèle sauvegardé est un dossier contenant des fichiers arbitraires et un descripteur `MLmodel`.

Saveur `python_function` : Le dénominateur commun. Tout modèle peut être chargé comme une fonction Python générique, permettant un déploiement sans réécriture de code.

Model Registry : Gouvernance et cycle de vie centralisés



Versioning

Gestion automatique des versions (v1, v2) sous un nom unique.

Aliases

Tags dynamiques (@champion) pour découpler le code de la version du modèle.

Annotations

Descriptions Markdown pour documenter la méthodologie.

Lineage

Lien direct vers le 'Run' MLflow d'origine.

MLflow 3.0 : L'ère de l'IA Générative et du LLMOps

ML Classique (Tabulaire)



Centré sur le Run

GenAI (LLMs & Agents)



Centré sur le Modèle (**LoggedModel**)



Observabilité (Tracing) : Suivi détaillé des chaînes d'appels LLM (LangChain, OpenAI). Capture des entrées, sorties et latence.



Streaming : Support natif du streaming de réponse.




Token Tracking : Suivi automatique des coûts et de l'usage des tokens.

MLflow apporte la rigueur de l'ingénierie logicielle au flou artistique des applications GenAI.

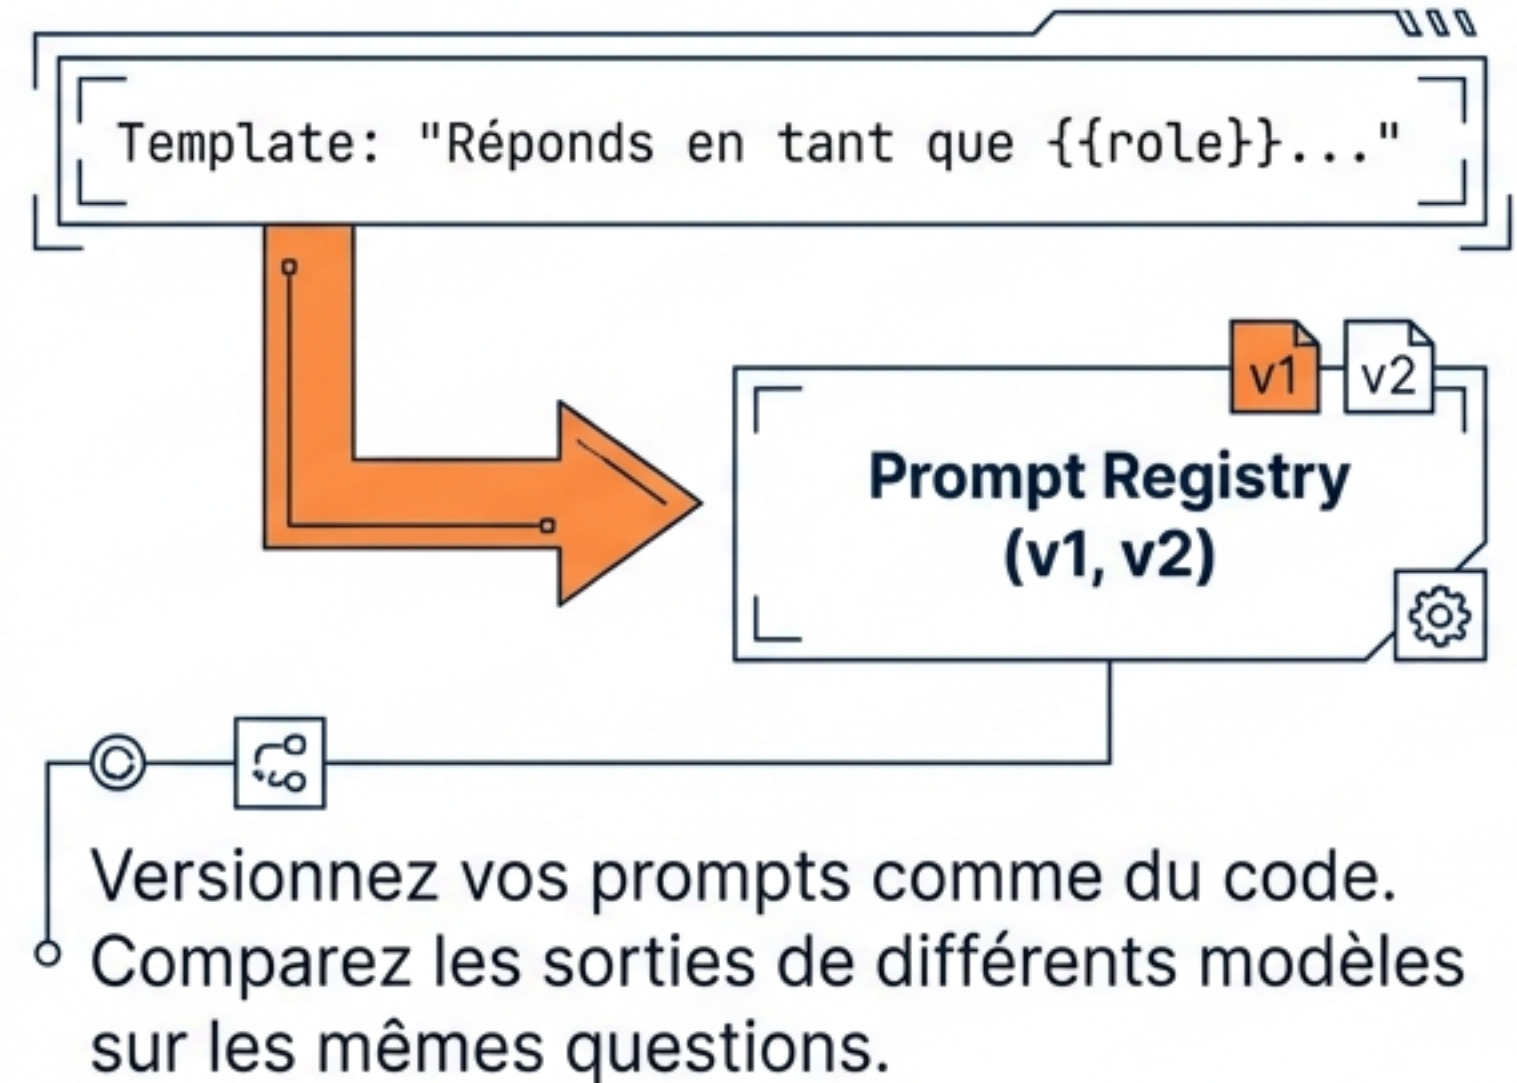
Évaluation GenAI et Ingénierie de Prompts

1 GenAI Evaluation Suite




Utilisation de 'LLM-as-a-judge' pour scorer automatiquement la qualité, le coût et la latence des réponses.

2 Prompt Engineering




Sécurité et Gestion des Accès : MLflow Gateway



Ne jamais exposer les clés API dans le code. Le Gateway gère l'authentification et route les requêtes de manière centralisée.

Intégration Profonde : L'exemple PyTorch

```
import mlflow
# Une seule ligne pour tout capturer
mlflow.pytorch.autolog()
```



Réduit le code 'boilerplate' et assure qu'aucune métrique critique n'est oubliée.

Déploiement en Production : Docker & Amazon SageMaker


Le flux 'Bring Your Own Container' (BYOC) automatisé.

MLflow Model



`mlflow sagemaker
build-and-push-container`

Amazon ECR



`mlflow deployments
create -t sagemaker`

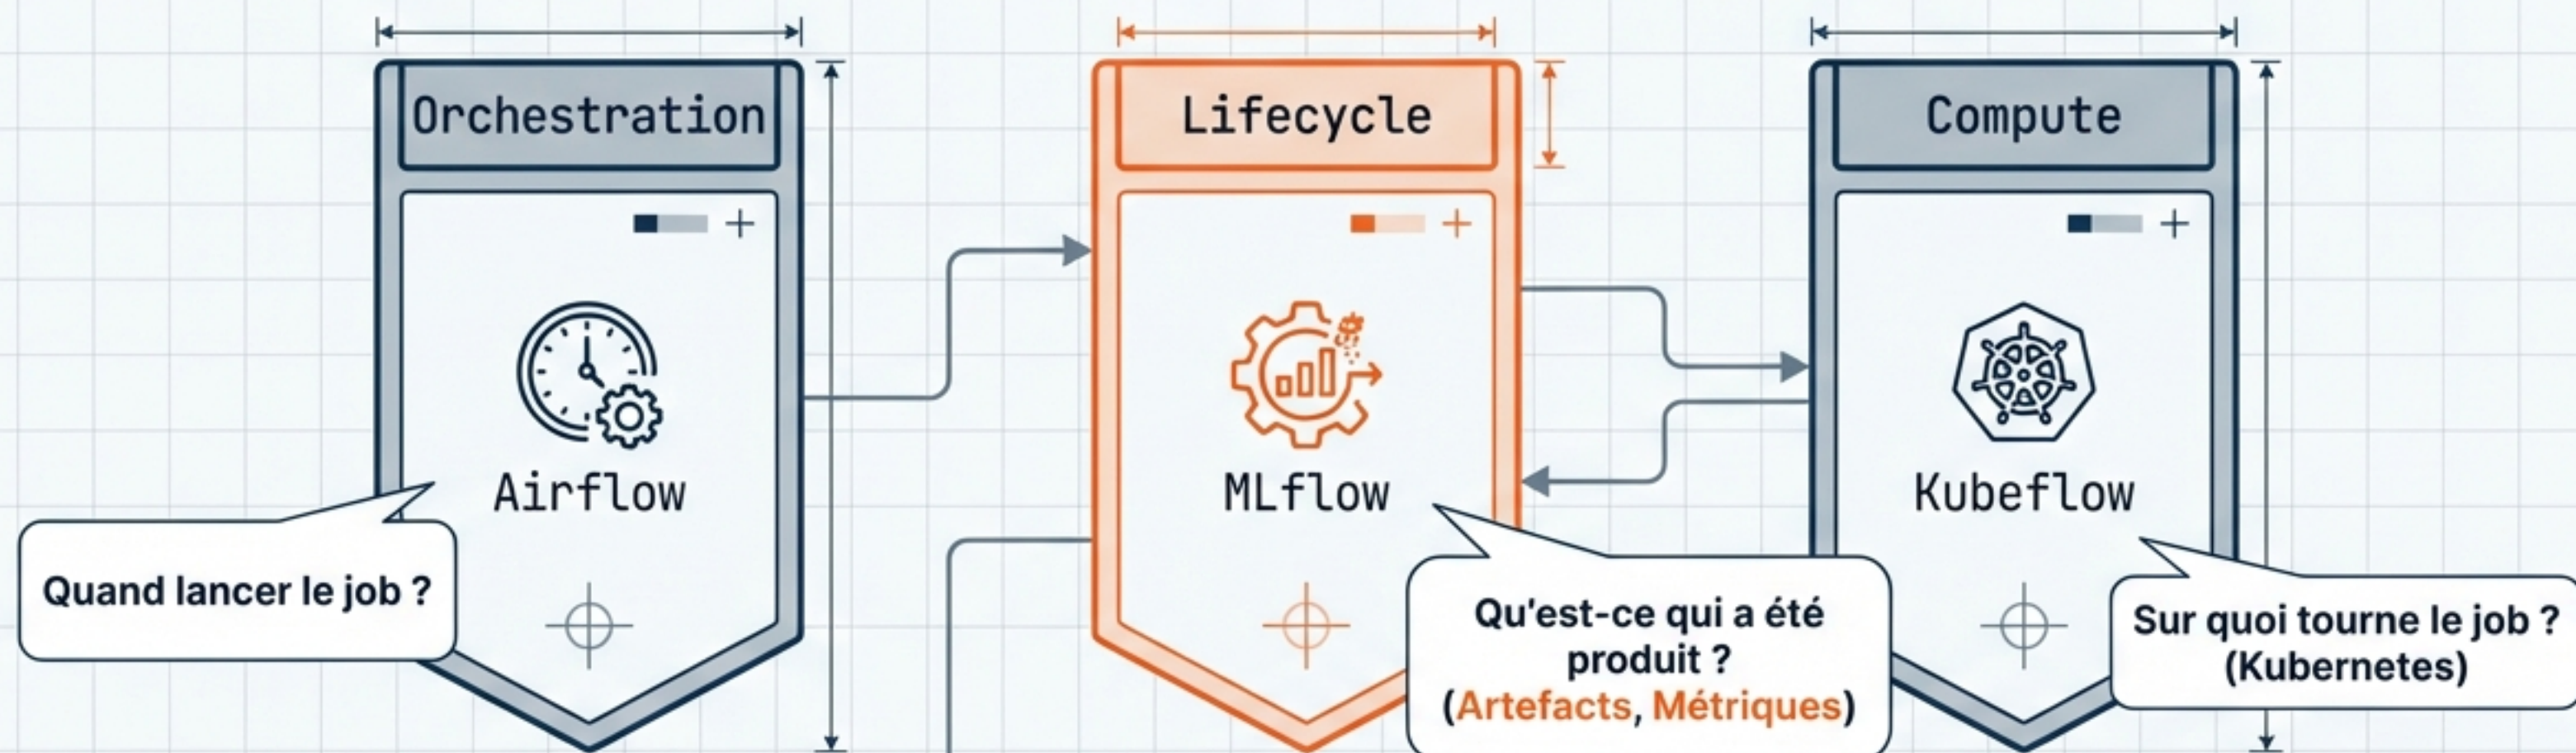
Amazon SageMaker
Endpoint



Endpoint REST
scalable et géré.

Possibilité de tester localement (`run-local`) avant le push cloud.
Tout le Dockerfile est généré automatiquement par MLflow.

Positionnement dans l'écosystème MLOps



Open Source vs Databricks Managed


Open Source	Databricks Managed
• Gratuit • Stockage Local/DB • Sécurité Manuelle 	✓ Unity Catalog (Gouvernance) ✓ Sécurité Entreprise (SSO) ✓ Serving Haute Performance ✓ Scalabilité Infinie 

Clarification : MLflow vs Airflow vs Kubeflow

Tool	Function	Question
 MLflow	Lifecycle Management TRACK & DEPLOY	How do I track and deploy?
 Airflow	Orchestration SCHEDULING	When does the job run?
 Kubeflow	Infrastructure COMPUTE	Where does the job run?

Ils sont complémentaires, pas rivaux. MLflow gère les **actifs** (modèles), Airflow gère le **temps** (scheduling), Kubeflow gère le **calcul**.

Synthèse : Du Chaos à la Clarté



Standardiser pour innover plus vite. MLflow est le système d'exploitation de vos applications IA.